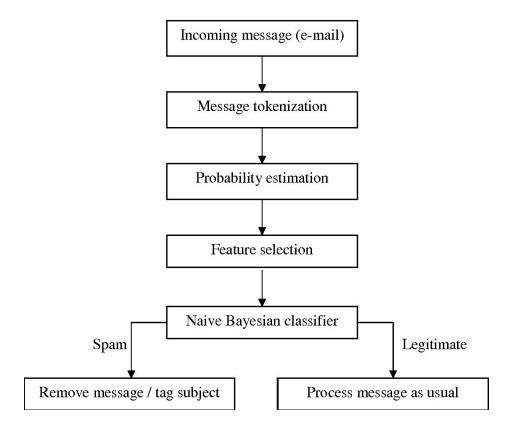
Bayes spam filter

by Timushev / Masmalieva

Popis principu použitého spam filtru

Podstatou metody statistické filtrace je použití Bayesovské matematické věty na příchozí písmena. Tato věta vám umožňuje vypočítat pravděpodobnost úspěšného dokončení nějaké události na základě statistik této události v minulosti.



Bayes /VS/ Content of the header

Řazení zpráv podle obsahu polí záhlaví umožňuje zbavit se určitého množství spamu. Některé klientské programy (například The Bat!) umožňují analyzovat záhlaví bez stahování celé zprávy ze serveru, a tím šetřit provoz.

Tato metoda je však povrchní a nebere v úvahu obsah. Skenování zjevné "spamové" hlavičky nesnižuje šanci klasifikovat mail jako spam. V důsledku toho je třeba takový filtr častěji trénovat a označovat chyby.

P.S. Použijte červené tlačítko v e-mailu, je to opravdu užitečné:)

Problemy

1. Problém vzácných slov.

Vyskytuje se, pokud se slovo během fáze učení nikdy neobjevilo: čitatel a jmenovatel jsou nulové, a to jak v obecném vzorci, tak ve vzorci spamu.

Obecně platí, že slova, s nimiž se program během fáze učení setkal jen několikrát, nejsou reprezentativní (ukázkový soubor dat je malý, aby mohl učinit spolehlivý závěr o vlastnosti takového slova).

 Algoritmus má také zásadní chybu: je založen na předpokladu, že některá slova jsou častější ve spamu a jiná v běžných e-mailech, a je neúčinný, pokud je tento předpoklad nesprávný.